

TÍTULO: MODELO ALGEBRAICO PARA LA OPTIMIZACIÓN DE LA AGENDA DE CITACIÓN DE LAS MUJERES INCLUIDAS EN EL PROGRAMA DE CRIBADO DE UNA UNIDAD DE PREVENCIÓN DEL CÁNCER DE MAMA.

MODALIDAD DE TRABAJO: trabajo práctico sobre un problema concreto.

AUTOR: EDUARDO ALCOBILLA-FERRARA (alcobilla_edu@gva.es)

PUESTO Y CENTRO DE TRABAJO: jefe de la Sección de Promoción y Programas de Salud. Centro de Salud Pública de Castellón.

RESUMEN

En el presente trabajo se aborda el problema del ausentismo en las agendas de citación de los programas de cribado poblacional para la prevención del cáncer de mama en la Comunidad Valenciana, cuya consecuencia directa es el paradójico efecto de generación de demoras con infrautilización de los recursos disponibles.

Se propone un modelo algebraico para la optimización de las agendas de mediante un proceso de sobrecitación controlada para compensar el ausentismo esperado, en base al comportamiento histórico de las pacientes a citar, lo que permite agruparlas en categorías con idéntico comportamiento y asociarles una probabilidad (experimental) de que asistan a la próxima cita. Para ello construimos una función lineal sometida a una serie de restricciones que optimizamos por el método del Simplex, sin perder de vista la capacidad máxima de una unidad y el riesgo de sobrecarga asistencial que calculamos con ayuda del método de convolución de binomiales y el método Montecarlo, todo lo cual nos permitirá finalmente determinar el número de jornadas de trabajo necesarias para citar a todas las pacientes.

Palabras clave: Agenda de citación de una UPCM, Ausentismo, Método del Simplex, Método Montecarlo, convolución de binomiales, sobrecitación controlada.

1. INTRODUCCIÓN

Mide lo que se pueda medir; y lo que no, hazlo medible
(¿Galileo Galilei? S.XVI-XVII)

El cribado poblacional para la prevención del cáncer de mama mediante la realización de una mamografía bienal en las mujeres entre 45-50 años y 65-70 años ha demostrado ser una medida eficaz para el diagnóstico precoz del cáncer de mama, con la consiguiente repercusión en tratamientos menos agresivos, y más eficaces en términos de curación/supervivencia de las pacientes afectadas (Apesteguía Ciriza y Pina Insausti, 2013; Sala et al, 2012).

El programa autonómico de prevención de cáncer de mama está regulado por la orden 4/2021 de 29 de octubre (Conselleria de Sanitat Universal i Salut Pública, 2021), y se articula sobre 24 unidades funcionales de prevención de cáncer de mama (UPCM) distribuidas en las tres provincias de la Comunitat Valenciana.

Un problema operativo recurrente y común en los programas de cribado, y en particular del cribado del cáncer de mama, es el ausentismo en el colectivo de mujeres incluidas en el programa y citadas para la realización de la mamografía de screening (previa historia clínica dirigida) (Barroso García, Ruiz Pérez et al, 2009; Muñoz-Sanz et al 2021; Barroso García et al, 2009; Scaf-Klorrp et al, 1995) cuya consecuencia directa es el paradójico efecto de generación de demoras con ción de los recursos disponibles. En la Comunitat Valenciana se encuentra actualmente en torno al 30% (Dirección General de Salud Pública, 2016), en línea con lo que se considera aceptable en la literatura para conseguir un impacto efectivo en el diagnóstico y tratamiento precoz del cáncer de mama (NHS England, 2022).

El presente trabajo propone la construcción de un modelo algebraico aplicable a la optimización de las agendas de citación de las UPCM.

2. OBJETIVO

Se trata de construir una función lineal que represente la citación de pacientes en una jornada ordinaria de trabajo de una UPCM con el objeto de maximizar la asistencia ajustada a su capacidad máxima de trabajo por medio de lo que podríamos denominar sobrecitación controlada, en base a la información disponible derivada del histórico de citas de cada paciente (asistencia / no-asistencia) para establecer una categorización de las mismas con una probabilidad de asistencia a la siguiente cita asociada, calculada en base a dicha información.

El formato matemático algebraico garantiza la transparencia, consistencia y reproducibilidad del modelo con los datos de cada UPCM, dada la previsible variabilidad en el comportamiento de las pacientes dependiendo de las singularidades de cada departamento de salud. Además, permitiría llegado el caso implementarlo en una aplicación informática que a través de un entorno más amigable para el usuario permitiera a este la incorporación de los datos y el cálculo de resultados con total transparencia, evitando el fenómeno del *black box* (Alcobilla-Ferrara, 2023)

Con el objeto de mostrar la dinámica de funcionamiento del modelo, tras presentarlo en su formato general para cualquier número de variables, lo reformulamos particularizado para el caso más elemental con dos categorías de pacientes, primeras visitas y segundas visitas, calculando la probabilidad de las primeras en base al comportamiento de este tipo de cita en el año previo, y la probabilidad de acudir de las sucesivas en base al comportamiento de las mujeres en su última cita registrada en el programa de cribado de cáncer de mama (Generalitat Valenciana, 2004) dado que trabajando en un espacio de dimensión dos es posible la representación en el plano (función y restricciones se comportan como espacios vectoriales de dimensión uno (rectas) dando hiperplanos de corte de dimensión cero

(puntos)) para visualmente poder mostrar el funcionamiento del simplex para alcanzar la optimización (maximización) de la función lineal propuesta.

3. METODOLOGÍA

3.1. Notación: categorización de las mujeres a citar y cálculo de probabilidades de que acudan a la cita siguiente.

Designaremos como θ_j cada una de las categorías según el número de citas históricas c_i consideradas y el comportamiento de las señoras (han acudido / no-han acudido), con $i = \{1, 2, \dots, n\}$, y $j = 2^i + 1 = \{3, 5, \dots, 2^n + 1\}$, reservando en ambos casos, el subíndice 0 para la categoría de primeras visitas (θ_0), y para la cita próxima (c_0) (fig. 1 del anexo).

Utilizando el modelo frecuentista (experimental) para el cálculo de probabilidades, la probabilidad de que una mujer perteneciente a cierta categoría θ_j acuda a la cita será

$$p(\theta_j) = \frac{\sum_{i=1}^n c_i}{n},$$

$$\text{con } IC_{95\%} = (p(\theta_j) - 1.96 * \sqrt{p(\theta_j)(1 - p(\theta_j))/n}, p(\theta_j) + 1.96 * \sqrt{p(\theta_j)(1 - p(\theta_j))/n})$$

(pudiendo tomarse cualquier valor entre los extremos del intervalo según el planteamiento sea más o menos conservador), y siendo $c_i = 0$ si la paciente no acudió a la cita, $c_i = 1$ si acudió a la cita, y n el número de citas históricas consideradas para el cálculo de probabilidades.

En el caso de la categoría de primeras visitas θ_0 recurriremos a la información del comportamiento histórico de esta categoría en el año precedente (salvo que haya una variabilidad sociodemográfica substancial en la población, en cuyo caso puede ser preferible un promedio de dicho valor en la serie histórica) para la asignación de $p(\theta_0)$.

Así si consideramos las n citas históricas previas de las señoras muestreadas, obtendremos $2^n + 1$ categorías.

Estos cálculos se efectuarán sobre un muestreo pseudoaleatorio simple sin reposición estratificado (según sean primeras visitas o visitas sucesivas) sobre el total de mujeres a citar. Dado que el número de pacientes que debe ser citado anualmente en una UPCM es alto (del orden de miles) un 5% del total suele ser un muestreo suficiente para que el número de mujeres en cada categoría resulte representativo en todas las categorías (Pérez López, 2020), aunque obviamente, cuanto mayor sea el tamaño del muestreo mayor será la precisión de los cálculos (aunque también mayor el consumo de tiempo y recursos humanos a la hora de revisar los históricos de los casos muestreados) (fig.2 del anexo).

3.2. Construcción de la función lineal objetivo.

Buscamos por tanto una función lineal entera de las variables θ_j y $p(\theta_j)$ que considere el ausentismo y permita optimizar la citación compensando aquel con una sobrecitación controlada medible. Dicha función es

$$z = \theta_0 p(\theta_0) + \theta_1 p(\theta_1) + \cdots + \theta_{2^n+1} p(\theta_{2^n+1})$$

En los casos en que se modelice categorizando a las señoras en más de 2 grupos, debería valorarse la introducción de una colección de $2^n + 1$ coeficientes $\alpha_{2^n} \in \mathbb{R}$

$$z = f(\theta_j p(\theta_j)) = \alpha_0 \theta_0 p(\theta_0) + \alpha_1 \theta_1 p(\theta_1) + \cdots + \alpha_{2^{n+1}} \theta_{2^{n+1}} p(\theta_{2^{n+1}})$$

para dar más peso al comportamiento de la paciente en la visita más reciente (por ser a priori más informativa), y tanto menor cuanto más antigua sea la cita considerada, lo que probablemente conduzca a un modelo más preciso.

3.3. Aplicación a una base de datos sintéticos, en dos dimensiones.

Mediante la IA Claude Sonnet 4.6 (Anthropic, 2025) creamos una base de datos sintéticos semejante a los datos reales. Formulamos así el siguiente problema:

- un determinado año debemos agendar para cierta UPCM un total de 23000 mujeres, de las cuales hay 3500 primeras visitas ($\theta_0 = 3500$) y 19500 sucesivas ($\theta_1 = 19500$) (por tanto, con $\theta_0 = 0.15(\theta_0 + \theta_1)$), con un total de días laborables de 218 (soslayando el número de días en los que el mamógrafo estará averiado, dato que también podría ser estimado según el comportamiento histórico del mismo por medio de una recta de regresión).
- Realizamos un muestreo pseudoaleatorio sin reposición sobre 1200 casos (5%) considerando la asistencia o no-asistencia de la paciente a la cita anterior en el caso de las sucesivas, y el porcentaje de participación de las primeras visitas en el año precedente.
- A partir de los 1200 casos muestreados calculamos la probabilidad de asistencia que resulta ser aproximadamente, para θ_0 , $p(c_0 = 1)_{\theta_0} \approx 0.70$ (por comodidad $p(\theta_0)$) con $IC_{95\%} \approx (0.67, 0.73)$, y para θ_1 , $p(c_0 = 1)_{\theta_1} \approx 0.80$ (por comodidad $p(\theta_1)$) con $IC_{95\%} \approx (0.77, 0.82)$.
- En base a los tiempos asignados por la administración a la atención de cada señora (historia clínica y mamografía) y la composición usual de una UPCM (un mamógrafo y dos TER, además del personal administrativo), establecemos como

capacidad máxima de la UPCM (con 5 horas de trabajo por jornada y 2 mujeres cada 10 minutos) en 55 mamografías / jornada ($\theta_0 p(\theta_0) + \theta_1 p(\theta_1) \leq 55$), admitiendo una sobrecitación máxima aceptable menor del 25% de modo que $\theta_0 + \theta_1 \leq 68$ mujeres.

- Además, ambos parámetros deben, ser positivos y no nulos ($\theta_0 > 0$, $\theta_1 > 0$)
- Por último, establecemos la condición de que en cada jornada se respete la proporción general entre primeras visitas y sucesivas ($\theta_0 = 0.15(\theta_0 + \theta_1)$)

Con estos datos, se plantean las siguientes cuestiones:

1) ¿cuál son los valores de θ_0 y θ_1 , que hacen máxima la función

$$z = \theta_0 p(\theta_0) + \theta_1 p(\theta_1)$$

2) ¿Cuál será el número de jornadas con sobrecarga asistencial?

3) ¿Cuántas jornadas de trabajo serán necesarias para citar al total de mujeres en el periodo dado?

3.4. Optimización de la función por el método del Simplex (Fig. 3. Código en Python

(Python Software Foundation , 2023) disponible en el repositorio GitHub:

<https://github.com/Eduardo-Alcobilla/Montecarlo-mammography.git>)

El método del Simplex fue desarrollado por G.B. Danzig (1963) en la segunda mitad del siglo pasado (Hiller y Lieberman, 2010), y persigue la optimización de una función lineal entera sujeta a restricciones lineales, mediante un proceso iterativo que mejora progresivamente la solución moviéndose de un vértice de la región factible de soluciones, resultante de la intersección de hiperplanos en un espacio vectorial de dimensión n , a otro buscando el mejor resultado posible, que es la maximización de la función $z = f(\theta_i p(\theta_i))$.

En la figura 3 del anexo se muestra de forma gráfica el funcionamiento de dicho método (numéricamente basado en operar con la matriz de datos según las reglas del cálculo de matrices del Álgebra Lineal).

En nuestro caso los valores que hacen máximo el valor de z ($z = 49$) son $\theta_0 = 10$ y $\theta_1 = 53$.

3.5. Cálculo del número de jornadas de sobrecitación por convolución de binomiales y por el Método Montecarlo (Fig. 4. Código en Python (Python Software Foundation , 2023) disponible en el repositorio GitHub: <https://github.com/Eduardo-Alcobilla/Montecarlo-mammography.git>), **y del número de jornadas totales anuales necesarias.**

Definimos sobrecarga asistencial C_{max} como cualquier jornada en la que el número real de mujeres asistentes X supera el número que hemos establecido como capacidad máxima de la UPCM, en nuestro caso $C_{max} = 55$. Dado que este número resulta de sumar dos variables binomiales independientes

$$\theta_0 \sim \text{Bin}(10; 0.7) \text{ con } E[X] \approx 7.0, \text{Var}[X] \approx 2.1$$

$$\theta_1 \sim \text{Bin}(53; 0.8) \text{ con } E[X] \approx 42.4, \text{Var}[X] \approx 8.5$$

y la convolución de distribuciones binomiales, nos da otra binomial de parámetros

$$X = \theta_0 + \theta_1, \text{ con } E[X] \approx 49.4, \text{Var}[X] \approx 10.6 \text{ y } DE[X] \approx 3.2,$$

la probabilidad de sobrecarga en una jornada cualquiera será

$$P(\text{sobrecarga}) = P(X > 55) = \sum_{k=56}^{68} P(X = k)$$

donde $P(X = k)$ se obtiene por convolución exacta de las dos distribuciones binomiales. La aproximación normal nos da una

$$P(Z > \frac{P(X > 55,5 - 49.4)}{3.25}) = P(Z > 1.88) \approx 1 - 0.97 \approx 0.03$$

Alternativamente se ha calculado el número de jornadas con sobrecarga y su distribución por medio del método Montecarlo (Kroese, Taimre, y Botev, 1999) con un millón de réplicas, obteniendo la distribución que se muestra en la figura 3 del anexo, con un 95% de jornadas en el rango (43, 55), y un 99% de jornadas en el rango (41, 57), con los parámetros resultantes del proceso de optimización por el método del Simplex.

Por tanto, a la vista de estos resultados podemos concluir que el número de primeras visitas que deben citarse es de 10, y el de sucesivas de 53, para conseguir un máximo de mujeres atendidas en torno a 53 / jornada, con una citación de 68 pacientes por debajo de la citación máxima establecida.

Así pues, harán falta aproximadamente 339 jornadas para citar y atender a todas las señoras de nuestro problema, lo que supone un total de 121 jornadas extraordinarias.

4. APLICABILIDAD y DISCUSION

El modelo propuesto ofrece una forma eficaz (a falta de validación del mismo) de optimización de las agendas de citación de las UPCM en aras a mejorar su rendimiento, con escaso coste en lo relativo a recursos humanos y nulo respecto a recursos materiales frente

a otras opciones como el desarrollo de campañas destinadas a la concienciación de las mujeres para reducir el ausentismo (deseable y en absoluto incompatible con el método propuesto).

Es un modelo transparente, reproducible, y consistente con la información disponible. Ofrece además la ventaja de su sencillez frente a otras opciones de modelización de la probabilidad del ausentismo, como los modelos estocásticos basados en el análisis de series temporales, el *clustering* por medio de *random forest* o los modelos dinámicos basados en el *machine learning* (Gareth, Witten, Hastie, y Tibshirani, 2021) lo que favorece su transparencia y facilita su utilización por los gestores de agendas de una UPCM, siendo además adaptable a los recursos disponibles.

Tiene asimismo la ventaja (ciertamente un inconveniente desde el punto de vista matemático-analítico) de ser un modelo que exige el sobreajuste a los datos de cada UPCM, con el objeto de conseguir la mayor precisión y bondad de ajuste posibles, dada la variabilidad esperable y constatable (Dirección General de Salud Pública, 2016; NHS England, 2022) en la tasa de participación de la población diana de cada UPCM en función de múltiples factores (entornos urbanos vs rurales, facilidad/dificultad de acceso a las instalaciones de la UPCM correspondiente, distribución de la edad de las mujeres del programa, nivel educacional...) cuyo análisis queda fuera del ámbito de este trabajo. Por tanto, aunque es un modelo generalizado en tanto que algebraico, debe ser particularizado para cada UPCM según los datos correspondientes de cada una de ellas.

Obviamente, caso de juzgarse pertinente, y previa validación del modelo, el formato algebraico permite su implementación como aplicación informática “amigable” para el nivel usuario del personal encargado de la programación de agendas de las UPCM.

5. REFERENCIAS BIBLIOGRÁFICAS

- Alcobilla-Ferrara, E. (2023). Introducción al machine learning en Senología. *Revista de Senología y Patología Mamaria*. doi:<https://doi.org/10.1016/j.senol.2023.100503>.
- Anthropic. (2025). Claude (version Claude Sonnet 4.6) [Modelo de inteligencia artificial].
Obtenido de <https://claude.ai>.
- Apesteguia Ciriza, L., y Pina Insausti, L. J. (2013). Cribado poblacional de cáncer de mama. Certezas, controversias. *Radiología*. doi:<http://dx.doi.org/10.1016/j.rx.2013.05.008>.
- Barroso García, P., Ruiz Pérez, I., Puertas deRojas, F., Parrón Carreño, T., y Corpas Nogales, E. (2009). Factores relacionados con la no participación en el programa de detección precoz de cáncer demama. *Gac Sanit*, 23(1), 44-48.
- Conselleria de Sanitat Universal i Salut Pública. (2021). Orden 4/2021, de 29 de octubre. *Diari Oficial de la Generalitat Valenciana*(9208), 45162-45170.
- Dantzig, G. B. (1963). *Linear Programming and Extensions*. Princeton: Princeton University Press.
- Dirección General de Salud Pública, G. V. (2016). EOLAS. Obtenido de <https://eolas.sp.san.gva.es>.
- Gareth, J., Witten, D., Hastie, T., y Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2ª ed.). Nueva York: Springer.
- Generalitat Valenciana. (2004). Sigma: sistema de información y gestión de mama. Horus Software.
- Hiller, F. S., y Lieberman, G. J. (2010). *Introducción a la investigación de operaciones* (9 ed.). Mexico: McGraw-Hill.
- Kroese, D., Taimre, T., y Botev, Z. (1999). *Monte Carlo Statistical Methods*. Springer.
- Muñoz-Sanz, J. J., Jiménez-Palomares, M., Garrido-Ardila, E. M., y Rodríguez-Mansilla, J. (2021). Non-Participation in Breast Cancer Screening in Spain and. *Cancers*, 13, 4331. doi:<https://doi.org/10.3390/cancers13174331>.

NHS England. (2022). *Breast screening programme: Non-attendance and DNA rates*.

Obtenido de <https://www.gov.uk/government/collections/breast-screening-programme-england-statistics>.

Pérez López, C. (2020). *Técnicas de muestreo estadístico*. Madrid: Garceta.

Sala, M., Salas, D., Zubizarreta, R., Ascunce, N., Rué, M., y Castells, X. (2012). Situación de la investigación en el cribado de cáncer de mama en España: implicaciones para la prevención. *Gac. Sanit.*, 26(6), 574-581.

Scaf-Klormp, W., van Sonderen, F. L., Stewart, R., van Dijck, J., y van den Heuvel, W.

(1995). Compliance after 17 years of breast cancer. *Journal of Medical Screening*, 2, 195-199.

6. ANEXO I: FIGURAS.




Figura 1. Categorización de las pacientes en un modelo en un espacio vectorial de n dimensiones, en base al histórico de n citas (izquierda) y en un espacio de dos dimensiones según el comportamiento en la última cita (derecha).




Figura 2. Diagrama de flujo ilustrando la secuencia de acciones en el proceso de optimización de una agenda de una UPCM (caso general a la izquierda y caso particular en un espacio bidimensional a la derecha).




Figura 3. Región factible del problema de optimización con tres restricciones y dos variables de decisión (θ_0 y θ_1) -área azul-. La estrella naranja indica el valor óptimo (máximo) de la función objetivo z (53 citas). La estrella verde indica el óptimo limitando el riesgo de sobrecarga asistencial al 2.5% (49 citas) (solución segura).




Figura 4. Distribución de la asistencia de pacientes a su cita en una simulación con un millón de réplicas por el método Montecarlo. Entre las líneas discontinuas rojas, área bajo la curva que incluye el 95% de jornadas, y entre líneas discontinuas azules área que incluye el 99% de jornadas.